FASE 1: PROYECTO

OPERACIONES DE APRENDIZAJE AUTOMÁTICO (EQUIPO 6)

Repositorio del Equipo 6

ÍNDICE

- Presentación
- Introducción y objetivo del Proyecto
- Analisis de Requerimientos
- Roles del Equipo
- Manipulación y preparación de datos
- Exploración y preprocesamiento de datos
- Versionado de datos
- Estructuración y Refactorización del Código
- Conclusiones y recomendaciones

EQUIPO 6

- A01797300 Iván David Villegas Quintero
- A01797557 Leonel Matus Climaco
- A01796851 Kenji Omar Ramírez Álvarez

Profesor titular: Dr. Gerardo Rodríguez Hernández

Profesor tutor: Jesús Antonio Low Castro

INTRODUCIÓN Y OBJETIVOS

• Introducción

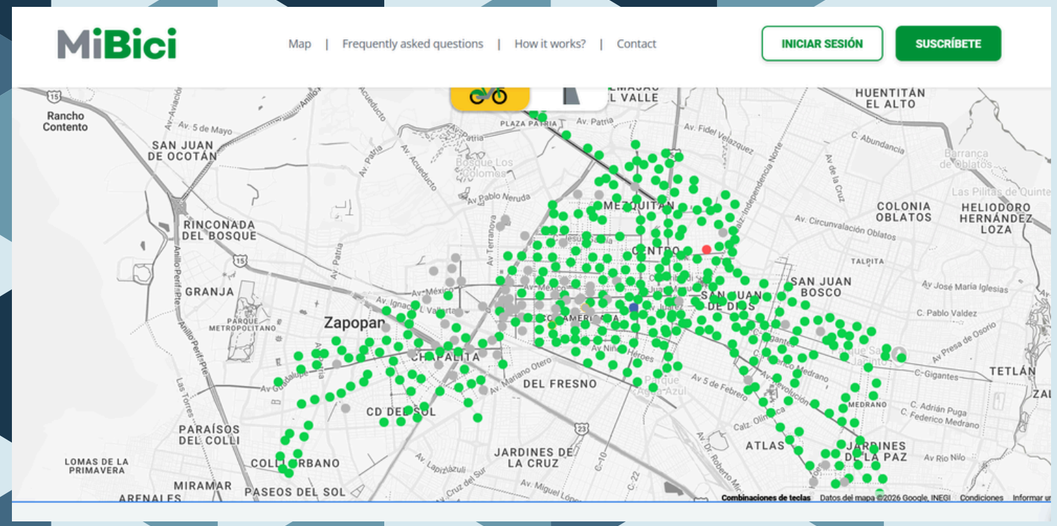
El sistema de bicicletas públicas MiBici sufre una fuerte asimetría en su demanda diaria durante las horas pico (07:00–09:00 y 18:00–20:00):

- Zonas residenciales: Quedan desabastecidas de bicicletas.
- Corredores corporativos y universitarios: Se saturan al máximo, impidiendo que los usuarios devuelvan las unidades.
- Consecuencia: Cuellos de botella operativos e insatisfacción de los usuarios.

• Objetivo específico

Desarrollar un pipeline reproducible e intragal usando MLOps para anticipar entradas y salidas por estación y calcular su balance, apoyando la revisión y planeación del personal operativo

CONTEXTO DE LOS DATOS Y SISTEMA MIBICI



Dataset:

Más de 39 millones de viajes registrados desde diciembre de 2014 hasta septiembre de 2026.

Infraestructura MiBici:

Gestionado por la Agencia Metropolitana de Servicios de Infraestructura para la Movilidad del AMG; cuenta con una red de entre 368 y 470 estaciones automatizadas que operan de 5:00 am a 12:59 am, integradas a la red de transporte Mi Movilidad.

Alcance de esta fase:

Los 12 meses de 2023, con 4,293,115 registros de entrada y 359 IDs de estación observados.

Elegimos un año completo para explorar patrones por hora, día y mes con un volumen manejable. La selección limita la generalización a otros años.

ANALISIS DE REQUERIMIENTOS

El Machine Learning Canvas (ML Canvas) permitió estructurar los elementos clave del proyecto, alineando objetivos, fuentes de datos, métricas de evaluación y propuesta de valor.
Este instrumento facilitó la comunicación entre los roles involucrados y sirvió como base para planificar el flujo completo de la fase de desarrollo del modelo predictivo.

Fase 1

La Fase 1 representa el pilar del proyecto MLOps, ya que define los requerimientos, así como la preparación, exploración y validacion inicla de los datos.

Un diseño bien estructurado en esta etapa garantiza reproducibilidad, trazabilidad y consistencia, sentando las bases para el despliegue automatizado en fases posteriores.

ML Canvas

MACHINE LEARNING CANVAS

Proyecto: Anticipar el balance de entradas y salidas por estación de MiBici

Diseñado Para: Personal de operación y planeación de MiBici Diseñado Por: Equipo 6 Fecha: octubre 2026 Iteración: Propuesta inicial .

TAREA DE PREDICCIÓN

Estimar por separado cuántas bicicletas llegarán y cuántas saldrán de cada estación en cada una de las próximas 1 a 4 horas, como alcance inicial sujeto a validación y viabilidad.

Cada observación corresponderá a una estación y una hora. A partir de ambas predicciones se calculará el balance:

Balance = entradas – salidas.

Un balance positivo indica que llegan más bicicletas de las que salen; uno negativo, que salen más de las que llegan; y cero, que llega y sale la misma cantidad. Mostrar entradas y salidas por separado permitirá distinguir estaciones sin movimiento de aquellas con mucha actividad, aunque ambas tengan un balance de cero.

Los resultados reales se conocerán al finalizar cada hora y disponer de sus registros.

DECISIONES

Apoyar al personal operativo de MiBici para identificar estaciones que requieren revisión preventiva por sus entradas y salidas previstas.

Al combinar las predicciones con información de bicicletas disponibles y capacidad de anclaje (externas al dataset de este proyecto), el operador podrá valorar el envío de una camioneta para abastecer una estación o retirar bicicletas. Se buscará dar margen para actuar, por ejemplo, entre 30 y 60 minutos antes de una situación crítica, según la información disponible y los tiempos de traslado.

La decisión y la cantidad de bicicletas a mover corresponderá al personal operativo. El prototipo no confirmará estaciones vacías o saturadas únicamente a partir del balance ni ordenará traslados automáticamente.

PROPUESTA DE VALOR

Facilitar al personal de operación y planeación la identificación anticipada de estaciones con desequilibrios o alta actividad, para apoyar decisiones preventivas de redistribución.

El beneficio esperado para las personas que utilizan MiBici es encontrar bicicletas para iniciar sus viajes y espacios disponibles para devolverlas, especialmente en periodos de mayor demanda. Este beneficio dependerá de las acciones del operador y deberá validarse, no puede demostrarse únicamente con los registros históricos de viajes.

La herramienta mostrará entradas, salidas y balance en tablas o gráficas. Permitirá consultar patrones históricos y distinguirlos de las predicciones futuras. El modelo se comparará con métodos sencillos para comprobar si aporta una mejora.

RECOLECCIÓN DE DATOS

Obtener los archivos de viajes de MiBici y conservar una copia de los datos originales con su procedencia y fecha de descarga.

Validar datos de estaciones, fechas de inicio y finalización de viajes, duplicados y registros incompletos. Contabilizar las entradas según el destino y la finalización del viaje, y las salidas según el origen y su inicio.

Construir registros por estación y hora con tres valores: entradas, salidas y balance. Contabilizar las llegadas cuando termina el viaje y las salidas cuando comienza. Distinguir ausencia de viajes por falta de información. Documentar las transformaciones y registrar las versiones de datos mediante MLflow y los scripts en GitHub.

FUENTES DE DATOS

Utilizar los archivos históricos del portal de datos abiertos de MiBici. Los campos indispensables son estación de origen, estación de destino, fechas, y horas de inicio y finalización de cada viaje.

Complementar con el catálogo de estaciones, para relacionar sus identificadores y nombres.

La cobertura temporal y las estaciones incluidas dependen de la disponibilidad y calidad verificadas. No se asumirá que estos archivos contienen inventarios de bicicletas ni movimientos realizados por el operador.

Para evaluar riesgo de estaciones vacías o saturadas se necesitan fuentes adicionales de inventario, capacidad y redistribuciones. Si no están disponibles, el alcance se limitará a anticipar entradas, salidas y balance, sin presentar estas estimaciones como disponibilidad real.

En esta primera versión se utilizarán únicamente datos de MiBici. Como trabajo futuro, se considerará incorporar información del clima, elementos de geolocalización, mapas, días festivos y eventos o cierres viales para evaluar si mejoran las predicciones de entradas y salidas. Su incorporación dependerá de la disponibilidad, calidad y acceso a esa información antes de generar cada predicción.

ML Canvas

SIMULACIÓN DE IMPACTO

Simular predicciones para cada una de las próximas 1 a 4 horas sobre períodos históricos posteriores al entrenamiento. Compararlas con patrones históricos de entradas y salidas por estación y horario, y utilizar también el balance cero como referencia para el balance.

Evaluar error absoluto medio (MAE) y raíz del error cuadrático medio (RMSE) por separado para entradas, salidas y balance. El MAE indicará cuánto se desvía en promedio cada predicción, y el RMSE penalizará más los errores grandes que podrían afectar la planeación operativa. Revisar cada resultado por estación y por anticipación de 1, 2, 3 o 4 horas, evitando que errores de entradas y salidas se compensen y ocultan un balance aparentemente correcto.

Una predicción incorrecta podría generar revisiones innecesarias u omitir desequilibrios relevantes. Los costos y errores tolerables deberán acordarse con el personal operativo. No se atribuyen ahorros o mejoras en disponibilidad sin evidencia adicional.

Se considerará útil si mejora las predicciones de referencia en periodos posteriores al entrenamiento y mantiene errores aceptables para la planeación. Los límites se definirán después del EDA y se documentará como supuestos cuando no puedan validarse con personal operativo.

La mejora en disponibilidad para las personas usuarias requeriría una evaluación posterior con inventarios e intervenciones operativas. Las predicciones horarias no demostrarán por sí solas que es posible intervenir con 30–60 minutos de anticipación.

GENERACIÓN DE PREDICCIONES

En cada ejecución se generarán estimaciones separadas de entradas, salidas y balance para cada una de las próximas 1 a 4 horas. Se propone renovar estas estimaciones cada hora, siempre que existan datos suficientemente recientes.

El personal operativo podrá seleccionar estaciones y visualizar los resultados en tablas o gráficas. Las consultas históricas podrán abarcar días, semanas o meses y mostrar patrones de actividad; esto no implica predecir meses completos hacia el futuro.

Inicialmente se simulará el funcionamiento con datos históricos, utilizando únicamente información disponible en cada momento simulado. La operación real requeriría una fuente de datos más actualizada que los archivos mensuales. El prototipo utilizará recursos locales y medirá sus tiempos de respuesta.

CONSTRUCCIÓN DE MODELOS

Evaluar modelos de regresión para predecir entradas y salidas por separado y calcular posteriormente el balance. La implementación podrá utilizar modelos independientes o un modelo con ambas salidas, según su complejidad y resultados.

Comparar métodos sencillos con referencias históricas. Separar entrenamiento, validación y prueba cronológicamente, ajustando las decisiones del modelo con validación y reservando la prueba para la evaluación final.

Evaluar el desempeño para cada anticipación de 1 a 4 horas y conservar únicamente las que alcancen resultados aceptables. Registrar experimentos en MLflow y medir recursos de entrenamiento. Actualizar los modelos según la incorporación de datos y el desempeño observado.

CARACTERÍSTICAS

Considerar la estación, la fecha y hora del periodo que se desea predecir, y resúmenes de entradas, salidas y balances de horas anteriores ya observadas. Mantener entradas y salidas separadas para representar tanto los desequilibrios como la cantidad de actividad.

Evaluar patrones asociados al día de la semana, fines de semana, mes y otras divisiones temporales que resulten útiles según el EDA. Las ventanas históricas y transformaciones se elegirán y documentarán posteriormente.

Los filtros de visualización no serán necesariamente variables del modelo. El modelo sólo utilizará información disponible antes de cada predicción.

ML Canvas

	MONITOREO  Revisar cobertura de estaciones y periodos, registros faltantes, consistencia de fechas y cambios en las distribuciones de entradas y salidas.	Cuando se conozcan los resultados reales, comparar los errores de entradas, salidas y balance con los métodos de referencia, por estación y para cada anticipación de 1 a 4 horas. Revisar también la actualización de los datos, el tiempo de respuesta y las consultas que el sistema no puede cubrir. Si posteriormente se dispone de inventarios y registros de intervención, evaluar también cuánto tiempo permanecen las estaciones sin bicicletas o sin espacios de anclaje y si las acciones preventivas reducen esos periodos.	La frecuencia de revisión se definirá según la publicación de datos y el uso previsto. Un deterioro deberá motivar una investigación antes de decidir entre corregir datos, ajustar el procesamiento o reentrenar.	

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

Datos de MiBici: https://mibici.net/en/open-data/

Archivo MLCanvas (Pantalla Completa)

ROLES DEL EQUIPO

Integrante	Rol Asignado	Actividades Realizadas e Interacción
Iván Villegas	MLOps Lead & Feature Engineer	Diseño e implementación del pipeline modular en src/mibici/ (features, train, predict). Integración del tracking de experimentos en MLflow. Creación y ejecución del notebook interactivo de EDA (1.0-eda.ipynb). Redacción del reporte técnico y Machine Learning Canvas.
Kenji Ramírez	Repository Owner & Data Architect	Administración del repositorio GitHub (ML_pipeline_eq6). Arquitectura de carpetas bajo Cookiecutter Data Science. Propuesta y modelado de fuentes de datos externas (catálogo GIS y capacidad de muelles). Revisión y validación de Pull Requests.
Leonel Matus Climaco	Data Engineer & Lineage Lead	Estandarización del esquema de versionado de datos mediante manifiestos JSON. Cálculo de checksums SHA-256 de los datasets Parquet. Gestión y empaquetamiento del almacenamiento de datos en Google Drive compartido.

MANIPULACIÓN Y PREPARACIÓN DE DATOS



Validamos los 12 archivos, columnas requeridas, identificadores, fechas y duplicados. De 4,293,115 registros se conservaron4,275,165 viajes.

Se descartaron 17,945 viajes con duraciones iguales o menores que cero y 5 viajes cuyo inicio o fin queda fuera de 2023. No hubo descartes por IDs, fechas inválidas o duplicados

Noviembre usa día/mes/año. El lector de datos con formatos explícitos y comprobación del mes de origen corrigió su cobertura y evitó interpretar fechas ambiguas.

Se conservaron 89,523 duraciones atípicas por IQR: una duración inusual no demuestra un movimiento inválido. Los nulos demográficos no afectan el conteo.

Estas reglas y sus efectos quedan registrados en reportes de calidad y MLflow, sin modificar los CSV originales.

Métricas de limpieza en MLflow

Reporte de calidad y transformaciones

PREPARACIÓN DEL CONJUNTO ANALÍTICO

Cada viaje suma una salida en la estación y hora de inicio y una entrada en la estación y hora de finalización. Balance = entradas menos salidas.

Cuadrícula horaria: 359 estaciones × 8,760 horas = 3,144,840 filas y 5 columnas. Se completan con cero las horas sin movimientos registrados.

Se añaden 10 variables de calendario, 12 retardos de 1, 2, 24 y 168 horas y 6 medias móviles de las 3 y 6 horas anteriores, separadas por estación.

Las medias móviles excluyen la hora actual. Al quitar las primeras168 horas por estación, quedan 3,084,528 filas, 33 columnas totales y 0 nulos.

Hora y día de semana tienen codificación seno/coseno. No se aplica escalado ni PCA para el flujo de árboles e interpretación.

Reporte de preparación

EXPLORACIÓN Y PREPROCESAMIENTO DE DATOS

Estadísticas por estación y hora: entradas, media 1.36 y desviación 2.70; salidas, media 1.36 y desviación 2.57; balance, media 0.00 y desviación 1.92.

Entre semana aparecen picos de actividad alrededor de las 08:00 y 18:00. Las tres horas con más salidas medias son 18:00, 08:00 y 17:00.

El promedio diario de salidas pasa de 13,136 de lunes a viernes a 8,189 en fin de semana: 37.7% menos.

Marzo registra el mayor promedio diario: 12,963 salidas. Diciembre, el menor: 10,104.

Perfil horario

Demanda por día de semana

Flujo mensual

EDA: BALANCE, ESTACIONES E HISTORIA TEMPORAL

48.54% de las horas no registra entradas ni salidas. Otro 8.85% tiene balance cero con movimientos en ambos sentidos. Balance cero puede coexistir con alta actividad.

Hay 572 combinaciones estación-mes sin movimientos. Sin calendario de operación no se puede distinguir falta de actividad, cierres o problemas de registro.

La estación 51 suma 76,910 desbalances horarios absolutos. El indicador depende del volumen de uso y no determina urgencia de redistribución ni inventario.

Correlaciones de enero–septiembre: con la misma hora de la semana anterior, entradas 0.78, salidas 0.75 y balance 0.47. Sugieren probar referencias semanales.

Desbalance por estación

Dinámica de la estación 51

Matriz de correlaciones

VERSIONADO DE DATOS

Cadena documentada: raw_v1, hourly_balance_2023_v2 y features_2023_v2. La versión horaria procede del origen y la preparada procede de la horaria.

Cada manifiesto conserva siete campos: id, archivo, sha256, url, origen, transformaciones y commit. El SHA-256 permite comprobar que todos usan el mismo archivo.

GitHub conserva código, manifiestos y evidencia. Drive almacena los datos. MLflow local conserva parámetros, métricas, esquemas y artefactos de las ejecuciones.

Las versiones previas se mantienen como historial. Los resultados de esta presentación corresponden a v2, con las fechas corregidas.

Manifiestos vigentes y enlaces de descarga

Archivos compartidos en Drive

EVIDENCIA DE MLFLOW

Experimento: mibici_balance_estaciones_2023. Tres ejecuciones con estado FINISHED: dataset, features y plots.

dataset: registra 4,293,115 filas de entrada, 17,950 descartes y 4,275,165 viajes válidos, además de las reglas y metadatos del conjunto horario.

features: registra 3,084,528 filas de salida, 33 columnas y 0 nulos. **plots**: registra estadísticas del EDA, seis gráficas y hallazgos.

Los **artefactos** incluyen código, entorno, reportes y documentación del versionado. Las capturas y la exportación de la API permiten revisar las ejecuciones sin acceder al servidor local.

Las tres ejecuciones de código

Datasets y esquema

Artefactos y gráficas

ESTRUCTURACIÓN Y REFACTORIZACIÓN DEL CÓDIGO

Cookiecutter Data Science organiza datos, notebooks, código, reportes y referencias.

mibici/**dataset.py**: carga, valida, limpia y agrega viajes por estación y hora.
mibici/**features.py**: construye calendario e historia temporal.
mibici/**plots.py**: centraliza el EDA y lo comparte con notebooks/archivo 1.0-eda.ipynb.
mibici/**tracking.py**: unifica el registro de metadatos y reportes en MLflow.

La refactorización evita duplicar la lógica entre notebook y terminal. No se añadieron clases innecesarias: POO se aplica cuando aporta valor.

Código reproducible y pruebas

CONCLUSIONES Y RECOMENDACIONES

La fase deja 4,275,165 viajes válidos, dos Parquet documentados y un flujo de limpieza, preparación y EDA que se puede ejecutar desde el repositorio.

La actividad cambia por hora, día y mes. Los desbalances observados no equivalen a inventario disponible.

Una ejecución sin errores puede conservar fechas equivocadas. Comprobar la cobertura de noviembre permitió corregir el conjunto de datos.

Limitaciones: solo se estudió 2023. Faltan inventario, capacidad y calendarios de operación.

Se establecen bases sólidas para evaluaciones posteriores, para continuar con implementaciones para el proyecto.

REFERENCIAS Y DECLARACIÓN DE USO DE IA

OpenAI. (2026). Codex [asistente de inteligencia artificial]. Se utilizó para depurar código, y revisar trazabilidad por medio de manifiestos.

MiBici

Cookiecutter DS

ML Canvas y licencia

Repositori Equipo 6

MLflow